FRIEDRICH-SCHILLER-
UNIVERSITÄT
JENA

GENESIS-Online

Die Datenbank des Statistischen Bundesamtes

Bundeskriminalamt

Integration historischer Kriminalitätsstatistiken in Deutschland (1984–2024)

Justin Bergmann | 05.04.2026

Inhaltsverzeichnis

- Motivation
- Data Extraction
- Schema Mapping & Data Translation
- Identity Resolution (Record Linkage)
- Data Fusion
- Data Quality Assessment
- Analyse & Ergebnisse (Der Überrepräsentationsfaktor)
- Fazit & Learnings

Motivation

- **Ausgangslage:** Häufige pro-Kopf-Überrepräsentation von Nichtdeutschen in polizeilichen Statistiken.
- **Forschungsfrage:** Spiegelt dies die reale Kriminalität wider oder gibt es Indizien für Racial Profiling (erhöhter Kontrolldruck)?
- **Datengetriebener Ansatz:** Direkter Vergleich von ermittelten Tatverdächtigen (PKS) und rechtskräftig Verurteilten (Justizstatistik) nach Nationalität.
- **Technische Herausforderung:** Harmonisierung dreier isolierter, strukturell heterogener Datensätze (PKS, Destatis Justiz & Zensus) in ein einheitliches Master-Schema.

Data Extraction

- **Polizeiliche Kriminalstatistik (BKA):**
  - Manuelle Extraktion von unstrukturierten Excel-Zeitreihen.
  - Strategischer Split: Bewusster Download in zwei getrennten Dateien ("Deutsch" / "Nichtdeutsch"), um das verbindende Attribut "Nationalität" zu sichern.

- **Justiz- & Bevölkerungsstatistik (Destatis):**
  - Automatisierter Abruf über die Genesis-API.
  - Ausgabeformat: Maschinenlesbare Flat-File-CSVs.

- **Strukturelle Hürden (Heterogenität):**
  - Extreme Unterschiede in der Granularität (Justiz enthält Alter/Geschlecht, Bevölkerung basiert auf Stichtagen und Bundesländern).

Schema Mapping & Data Translation

- **Methode:** Global-as-View (GAV)

- **Ziel:** Einheitliches Master-Schema für den finalen Join.

- **Kern-Transformationen:**
  - PKS: "Unpivoting" (Wide- zu Long-Format) zur Extraktion der Nationalität.
  - Justiz: Aggregation der hochgranularen Daten (Wegfall von Alter & Geschlecht).
  - Bevölkerung: Harmonisierung der Stichtage auf reine Jahreszahlen.

Identity Resolution (Record Linkage)

- **Das Problem:** Semantische Lücke zwischen 905 spezifischen Polizei-Delikten und 21 abstrakten Justiz-Kategorien.
- **Die Methode:** Erstellung eines "Many-to-One" Mapping-Dictionaries.
- **Der hybride Algorithmus (Python):**
  - Heuristiken (Regelbasiert): Automatisches Mapping über juristische Schlüsselwörter (z. B. "BtmG", "Mord").
  - Fuzzy String Matching: Lexikalische Textähnlichkeit (difflib) für die verbleibenden Delikte (mit striktem Schwellenwert zur Vermeidung von "False Positives").
  - Human-in-the-Loop: Manuelles Fine-Tuning der letzten Edge-Cases.

Data Fusion

- **Der Master-Join:** Verschmelzung von Polizei- und Justizdaten (Outer Join) über Jahr, Nationalität und Straftat_gemappt.
- **Die Anreicherung:** Anheften der historischen Bevölkerungsdaten (Left Join).
- **Datenbereinigung (Bugfixing):** Herausfiltern von Polizei-Sammelkategorien (z.B. "Straftaten insgesamt"), um massive Doppelzählungen zu verhindern.
- **Feature Engineering:** Berechnung der vergleichbaren Kriminalitätsraten (Fälle pro 100.000 Einwohner).

Data Quality Assessment

- **Historische Lücken (Missing Data):** Sichtbare Nullwerte in den polizeilichen Zeitreihen (z. B. 1984–1986) durch Platzhalter im Ursprungsformat.
- **Der "Wiedervereinigungs-Effekt":** Strukturbruch um 1990 (Sprung der Gesamtbevölkerung) erschwert absolute Längsschnittvergleiche.
- **Granularitätsverlust:** Die Identity Resolution erforderte die Aggregation hochspezifischer BKA-Delikte auf abstraktere Justiz-Kategorien.
- **Optimierungspotenzial:** Zukünftige Alterskorrektur (Herausrechnen von Kindern unter 14 Jahren) zur präziseren Berechnung der Kriminalitätsraten.

Analyse & Ergebnisse (Der Überrepräsentationsfaktor)

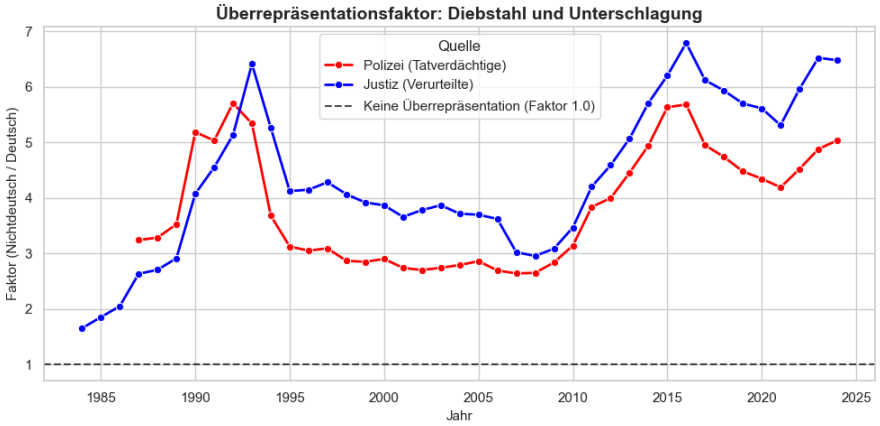

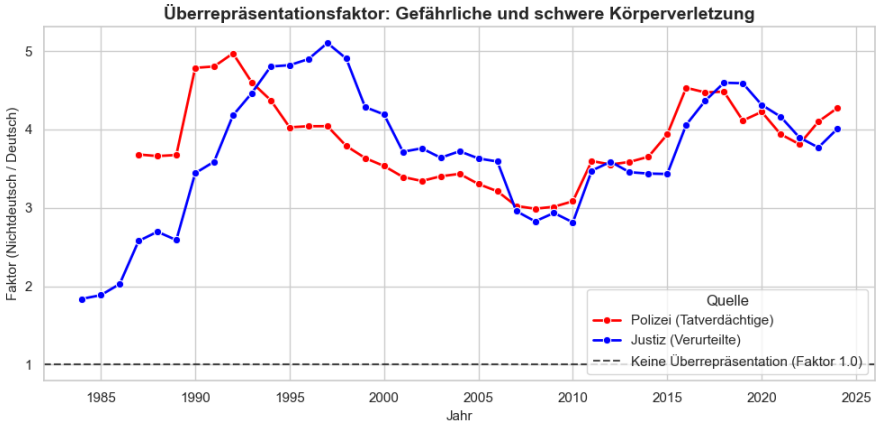

- **Die Metrik:** Der "Überrepräsentationsfaktor" (Rate der Nichtdeutschen geteilt durch Rate der Deutschen). Ein Faktor von 1.0 bedeutet absolute Gleichverteilung.

- **Fazit zur Forschungsfrage:** Diskrepanz zwischen Verdacht und Verurteilung liefert starke datengetriebene Indizien für selektive Wahrnehmung / erhöhten Kontrolldruck.

Fazit & Learnings

- **Inhaltliche Erkenntnis:** Die statistische Diskrepanz zwischen Eingang (Tatverdacht) und Ausgang (Verurteilung) stützt die Hypothese einer strukturellen Verzerrung.
- **Technische Erkenntnis 1 (Identity Resolution):** Bei juristischem Fachvokabular schlägt ein hybrider Ansatz (Domänen-Regeln + Fuzzy Matching) rein algorithmische Methoden deutlich.
- **Technische Erkenntnis 2 (Data Quality):** Versteckte Hierarchien in Tabellen (wie PKS-Sammelkategorien) sind das größte Risiko für fatale Doppelzählungen bei der Datenfusion.
- **Gesamtfazit:** Erfolgreiche Data Fusion ist nicht nur ein technischer SQL-Join, sondern erfordert zwingend tiefes inhaltliches Domänenwissen.

FRIEDRICH-SCHILLER-
UNIVERSITÄT
JENA

"If you torture the data long enough, it will confess."

– Ronald H. Coase

Vielen Dank für Ihre Aufmerksamkeit!

Justin Bergmann

Quellenverzeichnis

https://de.linkedin.com/posts/statistisches-bundesamt-destatis_statistischesbundesamt-datenbank-activity-7346424773578551296-ygUL

https://www.bka.de/DE/AktuelleInformationen/StatistikenLagebilder/PolizeilicheKriminalstatistik/pks_node.html